

Laboratório 01 - Representação

O objetivo deste laboratório é extrair representações e classificar comentários da base IMDB. O dataset proposto para esse Lab contém 50000 exemplos divididos em dois arquivos: `comments_train.txt` e `comments_text.txt`.

Os arquivos têm o formato mostrado abaixo com o comentário na coluna `review` e o rótulo na coluna `label`. Os comentários estão rotulados com duas classes: positivo (`pos`) e negativo (`neg`).

```
num,type,review,label,file
25000,train,"Story of a man who has unnatural feelings for a pig. Starts
out with a opening scene that is a terrific example of absurd comedy. A
formal orchestra audience is turned into an insane, violent mob by the
crazy chantings of it's singers. Unfortunately it stays absurd the WHOLE
time with no general narrative eventually making it just too off putting.
Even those from the era should be turned off. The cryptic dialogue would
make Shakespeare seem easy to a third grader. On a technical level it's
better than you might think with some good cinematography by future great
Vilmos Zsigmond. Future stars Sally Kirkland and Frederic Forrest can be
seen briefly.",neg,0_3.txt
```

Extraindo representações:

Você deve extrair e comparar ao menos duas representações diferentes, da sua escolha, e comparar com os resultados do TF-IDF (script disponível no moodle).

Classificando as representações:

As representações extraídas devem ser classificadas usando o kNN disponível no arquivo em anexo (kNN). Entretanto, você pode alterar os hiperparâmetros do kNN bem como as formas de normalização das características. O objetivo é maximizar a acurácia do classificador. Lembre-se de separar um pedaço da base de treinamento para validação.

O que deve ser entregue:

Um relatório com no máximo três páginas formato duas IEEE duas colunas (arquivo em anexo) descrevendo seus experimentos e resultados alcançados. O relatório deve ter o nível de detalhamento de forma que o leitor possa reproduzir os experimentos.