

Impactos da base de Aprendizagem

Aurélio Gabriel Ortiz Vieira
UFPR
Universidade Federal do Paraná - DINF
aurelio.ortiz741@gmail.com

Abstract

Este trabalho realiza uma comparação entre os modelos KNN, Naive Bayes (NB), Linear Discriminant Analysis (LDA), Logistic Regression (LR), Decision Trees (DT) e Support Vector Machines (SVM). Os modelos foram alimentados com blocos de 1000 em 1000 exemplos para o treinamento, até 10 mil exemplos, para classificar 58646 exemplos no teste. Os resultados mostram que SVM apresenta melhor desempenho para maior quantidade de dados de treino, no entanto, demorando 20.9 segundos para classificação sendo esse modelo mais lento, enquanto LR apresenta maior acurácia com menos dados, e com LDA fazendo a classificação mais rápida com 0.020 segundos.

1. Configuração dos Modelos

A base de dados de treinamento utilizada (`train.txt`) possui 20 000 linhas, mas a segunda metade é uma cópia exata da primeira, restando 10 000 exemplos únicos, manter as duplicatas inflava a validação cruzada até acurácia 1.0 por vazamento de dados entre treino e validação, por isso foram usados apenas os 10 000 exemplos únicos.

Os testes foram realizados utilizando a configuração apresentada abaixo. Os hiperparâmetros foram selecionados uma única vez, através de validação cruzada com 5 partições sobre os 10 mil exemplos de treino, e reaproveitados em todos os tamanhos de base (a validação cruzada não foi refeita para cada bloco de 1000 exemplos).

- `KNeighborsClassifier(n_neighbors=3, weights='distance', metric='manhattan')`
- `GaussianNB(var_smoothing=0.001)`
- `LinearDiscriminantAnalysis(solver='svd')`
- `LogisticRegression(max_iter=1000, random_state=0, C=0.1)`

- `DecisionTreeClassifier(criterion='gini', max_depth=20, min_samples_leaf=5)`
- `svm.SVC(C=10, gamma=0.001, kernel='rbf')`
- `StandardScaler()`, aplicado antes da classificação em KNN, LR e SVM

2. Acurácia de Acordo com Tamanho da Base de Treino




Figure 1. Acurácia no conjunto de teste em função do tamanho da base de treinamento, para cada classificador.

É possível ver pelo gráfico 1 que os classificadores NB e LDA possuem aumentos modestos na acurácia (0.012 e 0.024 entre 1 mil e 10 mil exemplos), conforme o aumento dos dados, estagnando já com 2 mil exemplos. KNN, LR e SVM apresentam também rápida estagnação, tendo um baixo aumento a partir de 3 mil exemplos (0.012, 0.011 e 0.017 até 10 mil exemplos, respectivamente), sendo LR

o modelo com maior desempenho com menos exemplos (1000 dados), e SVM maior acurácia total com mais dados. Nota-se que apesar de DT ter o menor desempenhos dentre todos, este é o mais afetado pela quantidade de dados, tendo um crescimento de cerca de 0.1 do ponto mais baixo (1000 exemplos) até o mais alto (8 mil exemplos). Assim, o tamanho da base deixa de ser relevante a partir de cerca de 2 mil exemplos para NB e LDA e de 3 mil exemplos para KNN, LR e SVM, enquanto a DT continua melhorando até 8 mil exemplos.

3. Tempo de classificação em 58k exemplos




Figure 2. Tempo para classificar as 58 646 amostras do conjunto de teste (escala logarítmica), com cada modelo treinado em 10 000 exemplos.

A Figura 2 mostra que LDA e DT são os mais rápidos (cerca de 0.02 s): o LDA aplica uma função discriminante linear, e a DT apenas percorre uma árvore de profundidade limitada, por isso seu tempo não depende do tamanho do treino. A LR também usa uma função linear (0.14 s). O NB leva 0.93 s, mais que os modelos lineares, pois avalia a verossimilhança gaussiana de cada classe e atributo para todos os exemplos. O KNN (3.6 s) precisa comparar cada exemplo de teste com os de treino, e por isso seu tempo cresce com a quantidade de dados. SVM com kernel RBF é a mais lenta (20.9 s), pois cada predição calcula o kernel contra todos os vetores de suporte, sendo cerca de mil vezes mais lenta que LDA e DT.

Vale destacar que KNN utilizou o parâmetro $n_jobs=-1$, que utiliza todos núcleos disponíveis para a classificação, além disso, o tempo de treino não foi contado, mas o uso de *StandardScaler()* é contado na classificação dos modelos que o utilizaram (KNN, LR, SVM).

4. Impacto dos Hiperparâmetros na Base de Treino

Foi realizada uma validação cruzada entre os modelos em 5 partições, testando diferentes hiperparâmetros. A

tabela 1 mostra os resultados dessa validação.

Modelo	Posição	Hiperparâmetros	Acurácia CV
KNN (30)	Melhor	Manhattan, $k=3$, distance	0.9561
	Meio	Euclidean, $k=7$, distance	0.9425
	Pior	Cosine, $k=11$, uniform	0.9313
NB (6)	Melhor	$var_smoothing = 10^{-3}$	0.9375
	Meio	$var_smoothing = 10^{-6}$	0.9286
	Pior	$var_smoothing = 10^{-2}$	0.9195
LDA (9)	Melhor	$solver = svd$	0.9568
	Meio	$solver = eigen$, $shrinkage = 0.1$	0.9541
	Pior	$solver = eigen$, $shrinkage = 0.5$	0.9379
LR (5)	Melhor	$C = 0.1$	0.9713
	Meio	$C = 10$	0.9690
	Pior	$C = 100$	0.9660
DT (24)	Melhor	$gini$, $max_depth = 20$, $min_samples_leaf = 5$	0.9109
	Meio	$gini$, $max_depth = 20$, $min_samples_leaf = 20$	0.8971
	Pior	$gini$, $max_depth = 5$, $min_samples_leaf = 1$	0.7420
SVM (11)	Melhor	RBF, $C=10$, $\gamma=0.001$	0.9738
	Meio	RBF, $C=10$, $\gamma=scale$	0.9614
	Pior	RBF, $C=1$, $\gamma=0.01$	0.9531

Table 1. Combinações de hiperparâmetros de maior (Melhor), mediana (Meio) e menor (Pior) acurácia média na validação cruzada (5 partições), para cada modelo. Entre parênteses, o número n de combinações testadas; a combinação do meio é a de posição $\lceil n/2 \rceil$ no ranking.

Através da tabela 1 é possível notar que com exceção de DT os demais modelos sofrem uma variação modesta de acurácia a depender dos hiperparâmetros: a diferença entre a melhor e a pior combinação é de 0.005 na LR e de 0.018 a 0.025 em KNN, NB, LDA e SVM, enquanto na DT chega a 0.169 (o pior caso é profundidade máxima 5).

5. Matriz de Confusão

Através da Figura 3 percebe-se que entre KNN, NB, LDA e DT a classe 5 é frequentemente classificada como classe 3, no entanto, o contrário praticamente não ocorre em KNN, NB e LDA (classe 3 classificada como 5, no máximo 0.5% da classe), sendo mais frequente na DT (2.2%), com a confusão ocorrendo principalmente em um sentido.

Apenas LR e SVM não ultrapassam a fração de 0.04 de classificação errônea, resultado condizente com a curva de acurácia observada, apesar disso, o terceiro maior desempenho (KNN), se aproxima das matrizes de confusão de SVM e LR, se não fosse pela maior fração de erro em classificar 5 como 3.

Ao observar a coluna 3 e 2 da matriz de NB, este parece ter um viés para as classes 3 e 2, com a coluna 3 apresentando previsão errada ao longo das classes, enquanto a coluna 2 exibe valores mais concentrados na classe 1 e 7.




Figure 3. Matrizes de confusão no conjunto de teste (modelos treinados com 10 000 exemplos). Cada linha é normalizada pela classe real; a diagonal (acertos) está em cinza, e as cores indicam a fração de cada classe confundida com outra.

5.1. Erros em Comum entre Modelos

	KNN	NB	LDA	LR	DT	SVM	Todos
KNN	2744	64%	65%	52%	64%	51%	28%
NB	35%	5060	47%	38%	51%	33%	15%
LDA	42%	56%	4231	47%	56%	39%	18%
LR	55%	72%	76%	2629	64%	67%	29%
DT	21%	31%	28%	20%	8317	18%	9%
SVM	62%	72%	71%	77%	66%	2287	33%

Table 2. Percentual dos erros do modelo da linha que também são erros do modelo da coluna, com treino de 10 000 exemplos. A diagonal (em negrito) é o total de erros de cada modelo. A coluna *Todos* indica a fração dos erros do modelo que são cometidos simultaneamente pelos seis modelos (756 exemplos).

Os erros não são os mesmos entre os classificadores: apenas 756 dos 58 646 exemplos de teste (1.3%) são classificados incorretamente pelos seis modelos ao mesmo tempo. Observando a tabela 2, DT se destaca por aparentar apresentar poucos erros em comum com os demais modelos, no entanto, o percentual baixo se deve por conta do número total de erros de DT. 33% dos erros do SVM é compartilhada entre os demais modelos, o que sugere exemplos difíceis, e não deficiência nos algoritmos.

6. Conclusão

O presente trabalho foi feito com intuito de observar os impactos de diferentes configurações de entrada, treino

com blocos de 1000 em 1000 exemplos, diferentes hiperparâmetros, em 3 métricas de desempenho, acurácia, tempo de classificação e matriz de confusão, em KNN, NB, LDA, LR, DT e SVM. O tamanho da base de treino deixa de ser relevante a partir de cerca de 2 mil exemplos para NB e LDA e de 3 mil para KNN, LR e SVM, enquanto a DT continua melhorando até 8 mil. Com poucos dados (1000 exemplos), LR demonstrou maior desempenho, e com todos os dados SVM apresentou a melhor acurácia (0.961), mas levando mais tempo para classificar (20.9 s). DT e LDA com tempos em cerca de 0.02 s foram os mais rápidos, no entanto, DT teve a pior acurácia. Os hiperparâmetros tiveram impacto modesto (diferenças de 0.005 a 0.025 entre a melhor e a pior combinação), exceto na DT (0.169). Quanto às matrizes de confusão, os erros não são os mesmos entre os classificadores: apenas 756 exemplos de teste (1.3%) são errados pelos seis modelos, e a classe 5 é frequentemente classificada como 3 em KNN, NB, LDA e DT.

References